

Προγραμματιστική Εργασία Πρόβλεψη κόστους ασφάλισης οχημάτων

Χαρά Τσίρκα, Πρόδρομος Αβραμίδης, and Γεώργιος
Γεροντίδης

{ctsirka, pavramidis, ggerontidis}@e-ce.uth.gr
8 εξάμηνο



Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών
Υπολογιστών
Πανεπιστήμιο Θεσσαλίας, Βόλος

Εξόρυξη Δεδομένων 2023-24
Διδάσκον: Μ.Βασιλακόπουλος

Μάιος 2024

1 Εισαγωγή

Η εργασία μας επικεντρώνεται στην πρόβλεψη του κόστους ασφάλισης μηχανοκίνητων οχημάτων. Η ανάλυση αυτή αποτελεί ένα κρίσιμο ζήτημα στον τομέα της ασφάλισης, καθώς επιτρέπει στους ασφαλιστές να προσδιορίζουν με μεγαλύτερη ακρίβεια τα ασφαλιστικά ασφάλιστρα, λαμβάνοντας υπόψη διάφορους παράγοντες που επηρεάζουν το κόστος. Η διαδικασία της εργασίας ξεκινά με την προ-επεξεργασία των δεδομένων, κατά την οποία πραγματοποιήθηκε εξερευνητική ανάλυση (exploratory analysis) για τον προσδιορισμό των κριτηρίων διαχωρισμού των δεδομένων. Κατά τη διάρκεια αυτής της ανάλυσης, μετρήθηκε ο βαθμός επίδρασης κάθε χαρακτηριστικού (feature) του συνόλου δεδομένων στα αποτελέσματα. Με τη βοήθεια διαγραμμάτων, καταφέραμε να επιλέξουμε τον κατάλληλο διαχωρισμό των δεδομένων για περαιτέρω ανάλυση. Στη συνέχεια, στην εργασία έχουμε προχωρήσει στη δημιουργία και αξιολόγηση των μοντέλων πρόβλεψης xgboost, RandomForest και ενός NeuralNetwork και στην οπτικοποίηση και αξιολόγηση των αποτελεσμάτων τους.

2 Περιγραφή dataset

Το dataset το οποίο επιλέξαμε αποτελείται από 30 μεταβλητές (columns) και 105555 εγγραφές. Στους παρακάτω πίνακες δίνεται μία σύντομη περιγραφή της κάθε μεταβλητής:

Μεταβλητή	Περιγραφή
ID	Εσωτερικός αριθμός αναγνώρισης που εκχωρείται σε κάθε ετήσια σύμβαση που επισημοποιείται από έναν ασφαλισμένο. Κάθε ασφαλισμένος μπορεί να έχει πολλές σειρές στο σύνολο δεδομένων, που αντιπροσωπεύουν διαφορετικές προσόδους του προϊόντος.
Date_start_contract	Ημερομηνία έναρξης του συμβολαίου (HH/MM/YYYY).
Date_last_renewal	Ημερομηνία τελευταίας ανανέωσης του συμβολαίου (HH/MM/YYYY).
Date_next_renewal	Ημερομηνία επόμενης ανανέωσης του συμβολαίου (HH/MM/YYYY).
Distribution_channel	Κανάλι μέσω του οποίου έγινε το ασφαλιστήριο, 0: για Πράκτορα, 1: για Ασφαλιστικοί μεσίτες.
Date_birth	Ημερομηνία γέννησης του ασφαλισμένου που δηλώνεται στο ασφαλιστήριο (HH/MM/YYYY).
Date_driving_licence	Ημερομηνία έκδοσης της άδειας οδήγησης του ασφαλισμένου (HH/MM/YYYY).

Μεταβλητή	Περιγραφή
Seniority	Συνολικός αριθμός ετών που ο ασφαλισμένος έχει συνδεθεί με την ασφαλιστική οντότητα, υποδεικνύοντας το επίπεδο αρχαιότητάς του.
Policies_in_force	Συνολικός αριθμός συμβολαίων που κατείχε ο ασφαλισμένος στην ασφαλιστική οντότητα κατά την περίοδο αναφοράς.
Max_policies	Μέγιστος αριθμός συμβολαίων που είχε ποτέ σε ισχύ ο ασφαλισμένος με τον ασφαλιστικό φορέα.
Max_products	Μέγιστος αριθμός προϊόντων που κατέχει ο ασφαλισμένος ταυτόχρονα σε οποιαδήποτε δεδομένη χρονική στιγμή.
Lapse	Αριθμός πολιτικών που ο πελάτης έχει ακυρώσει ή έχει ακυρωθεί λόγω μη πληρωμής κατά το τρέχον έτος λήξης, εξαιρουμένων αυτών που έχουν αντικατασταθεί από άλλο συμβόλαιο.
Date_Lapse	Ημερομηνία ακύρωσης της σύμβασης (HH/MM/YYYY).
Payment	Τελευταία μέθοδος πληρωμής της πολιτικής 1: εξαμηνιαία πληρωμή, 0: ετήσια πληρωμή
Premium	Καθαρό ποσό ασφαλιστρού που σχετίζεται με το ασφαλιστήριο συμβόλαιο κατά τη διάρκεια του τρέχοντος έτους.
Cost_claims_year	Συνολικό κόστος ζημιών που πραγματοποιήθηκαν για το ασφαλιστήριο συμβόλαιο κατά τη διάρκεια του τρέχοντος έτους.
N_claims_year	Συνολικός αριθμός ζημιών που πραγματοποιήθηκαν για το ασφαλιστήριο συμβόλαιο κατά τη διάρκεια του τρέχοντος έτους.
N_claims_history	Συνολικός αριθμός απαιτήσεων που υποβλήθηκαν καθ' όλη τη διάρκεια του ασφαλιστηρίου συμβολαίου.
R_Claims_history	Παρέχει μια ένδειξη του ιστορικού συχνότητας αξιώσεων του ασφαλιστηρίου.
Type_risk	Τύπος κινδύνου για κάθε όχημα 1: μοτοσικλέτα, 2: μικρά φορτηγά, 3: επιβατικά οχήματα, 4: αγροτικά οχήματα
Area	0: αγροτική περιοχή, 1: αστική περιοχή (>30.000 κάτοικοι όσον αφορά τις κυκλοφοριακές συνθήκες)
Second_driver	1: περισσότεροι από ένας δηλωμένοι οδηγοί 0: μόνο ένας δηλωμένος οδηγός
Year_matriculation	Έτος καταχώρησης οχήματος (YYYY)
Power	Ίπποι δύναμης οχήματος
Cylinder_capacity	Χωρητικότητα κυλίνδρων του οχήματος
Value_vehicle	Αξία αγοράς οχήματος στις 31/12/2019
N_doors	Αριθμός θυρών οχήματος
Type_fuel	Τύπος καυσίμου, P: πετρέλαιο, D: ντίζελ
Length	Μήκος του οχήματος σε m
Weight	Βάρος του οχήματος σε kg

3 Data preprocessing

Το πρώτο βήμα για την προεπεξεργασία των δεδομένων ήταν να κρατήσουμε μία γραμμή για κάθε 'ID'. Σε ένα 'ID' μπορεί να αντιστοιχούν περισσότερες από μία γραμμές που αντιπροσωπεύουν το ίδιο συμβόλαιο του ίδιου πελάτη για διαφορετική χρονική περίοδο. Έτσι, για κάθε 'ID' κρατάμε την τελευταία ανανέωση του συμβολαίου, δηλαδή την γραμμή με το μεγαλύτερο χρονολογικά 'last_renewal_date'. Έπειτα, στη θέση του 'premium' υπολογίζουμε και τοποθετούμε τον μέσο όρο των 'premium' όλων των γραμμών με κοινό 'ID'.

Το δεύτερο βήμα ήταν η επεξεργασία όλων των ημερομηνιών. Ειδικότερα, οι στήλες 'Date_birth', 'Date_driving_license', 'Date_start_contract', 'Date_last_renewal', 'Date_next_renewal', 'Date_lapse' δίνονται στην μορφή HH/MM/YYYY. Αρχικά, για κάθε μία από αυτές τις μεταβλητές κρατήσαμε το έτος (YYYY) και στην συνέχεια πραγματοποιώντας τις κατάλληλες αφαιρέσεις δημιουργήσαμε νέες στήλες στο dataset που πήραν την θέση αυτών που αναφέρθηκαν νωρίτερα. Έτσι, δημιουργήσαμε τις στήλες: 'Age' που προσδιορίζει την ηλικία του πελάτη, 'Years_driving' που προσδιορίζει πόσα χρόνια οδηγεί ο πελάτης, 'Year_on_road' που προσδιορίζει πόσα χρόνια κυκλοφορεί το κάθε όχημα υπό την κατοχή συγκεκριμένου πελάτη, 'Policy Duration' που υποδεικνύει την διάρκεια του εκάστοτε συμβολαίου σε χρόνια και 'Years_on_policy' που προσδιορίζει πόσα χρόνια ο πελάτης βρίσκεται στον ίδιο τύπο συμβολαίου. Πρέπει να σημειωθεί πως το dataset περιέχει δεδομένα μέχρι και το 2019. Για να έχουμε μια σωστή εικόνα των χρονολογιών σε όλες αυτές τις μεταβλητές που δημιουργήσαμε, χρησιμοποιήσαμε ως σημείο αναφοράς την χρονολογία τελευταίας ανανέωσης του συμβολαίου. Για παράδειγμα η μεταβλητή 'Age' προκύπτει από την αφαίρεση: 'Age' = 'Date_last_renewal' - 'Date_birth'.

Επιπλέον, δημιουργήσαμε μία ακόμη νέα στήλη με όνομα 'accidents' για να υπάρξει μια συσχέτιση μεταξύ των αριθμών των ατυχημάτων με τα χρόνια που ένας πελάτης είναι ασφαλισμένος στην εταιρεία.

Διαχειριστήκαμε την απουσία τιμών με δύο τρόπους. Στην στήλη 'Length' αντικαταστήσαμε τα κενά πεδία με τον μέσο όρο των τιμών της στήλης. Στην στήλη 'Type_fuel' αντικαταστήσαμε τα κενά πεδία με την τιμή 'Unknown'.

Μετά από δοκιμές διαπιστώσαμε πως κάποιες μεταβλητές του dataset δεν συνεισφέρουν καθόλου στην βελτίωση της απόδοσης και παραλείφθηκαν. Οι στήλες που χρησιμοποιήθηκαν τελικά είναι οι: 'Seniority', 'Premium', 'Type_risk', 'Area', 'Power', 'Second_driver', 'Years_on_road', 'R_claims_history', 'Years_on_policy', 'accidents', 'Value_vehicle', 'Age', 'Years_driving', 'Distribution_channel', 'N_claims_history', 'Cylinder_capacity', 'Weight', 'Length', 'Type_fuel', 'Payment', 'Contract_year', 'Policies_in_force', 'Lapse'.

4 Εκπαίδευση μοντέλου

Αρχικά εκπαιδεύσαμε τα μοντέλα με όλους τους τύπους οχημάτων και ύστερα από παρατήρηση των αποτελεσμάτων, φαινόταν καλύτερη η επιλογή να εκπαιδεύσουμε τα μοντέλα με κάθε τύπο οχήματος ξεχωριστά. Όπως φαίνεται καθαρά και από την ενότητα 5 [Εικ. 1] με τα διαγράμματα και τις παρατηρήσεις τους (Παρατήρηση 1).

XGBoost Parameters

(Στις παρενθέσεις βρίσκεται το συνηθισμένο εύρος τιμών, δηλαδή το εύρος που έγιναν οι δοκιμές για να πετύχουμε το μέγιστο επιθυμητό αποτέλεσμα.)

Objective (linear):

Το 'reg:squarederror' είναι το προεπιλεγμένο και ευρέως χρησιμοποιούμενο loss function για regression tasks, παρέχοντας ένα σαφές πλαίσιο για τη βελτιστοποίηση του μοντέλου XGBoost. Συγκεκριμένα, είναι κατάλληλο για την πρόβλεψη ασφάλιστρων, καθώς στοχεύει στην επίτευξη υψηλής ακρίβειας στην πρόβλεψη της συνεχούς τιμής των ασφάλιστρων.

Eval_metric ('rmse', 'mae'):

Για το eval_metric, επιλέξαμε το 'rmse' (Root Mean Squared Error) επειδή είναι ένα ευρέως αποδεκτό μέτρο για regression tasks. Αναλυτικότερα, δίνει μεγαλύτερη βαρύτητα σε μεγαλύτερες αποκλίσεις (λάθη) μεταξύ πραγματικών και προβλεπόμενων τιμών, γεγονός που μπορεί να είναι χρήσιμο στην ασφαλιστική πρόβλεψη όπου τα μεγάλα λάθη μπορεί να είναι πιο σοβαρά.

Learning_rate (0.001-0.3):

Ο ρυθμός μάθησης (learning rate) επηρεάζει πόσο γρήγορα προσαρμόζεται το μοντέλο κατά την εκπαίδευση. Επιλέχθηκε η τιμή 0.01 έπειτα από δοκιμές, διότι όντας χαμηλή σχετικά τιμή επιβραδύνει τη διαδικασία μάθησης, μειώνοντας την πιθανότητα υπερβολικής προσαρμογής (overfitting).

Max_depth (3-10):

Το μέγιστο βάθος των δέντρων στο μοντέλο. Ένας μεγαλύτερος αριθμός επιτρέπει πιο περίπλοκα δέντρα, αλλά μπορεί να οδηγήσει σε overfitting, επομένως επιλέχθηκε η τιμή 6.

Min_child_weight (1-10):

Ελάχιστο βάρος που πρέπει να έχει ένας κόμβος για να διαχωριστεί. Επηρεάζει την ευαισθησία του μοντέλου στις διακυμάνσεις στα δεδομένα. Ύστερα από δοκιμές προτιμήθηκε ο αριθμός βάρους 5.

Subsample (0.5-1):

Αναφέρεται στο ποσοστό των δειγμάτων που θα χρησιμοποιηθούν σε κάθε επανάληψη της εκπαίδευσης. Ένα ποσοστό 0.8 σημαίνει ότι το 80

Colsample_bytree (0.5-1):

Το ποσοστό των χαρακτηριστικών (columns) που θα επιλεγθούν τυχαία για να κατασκευάσουν κάθε δέντρο στο μοντέλο. Ένα ποσοστό 0.8 σημαίνει ότι το 80

N_estimators (100-2000):

Ο αριθμός των δέντρων που θα κατασκευαστούν στο μοντέλο. Δοκιμάστηκαν διάφοροι αριθμοί, συμπεριλαμβανομένων μεγαλύτερων από 1000, αλλά δεν υπήρχε μεγάλη βελτίωση στην απόδοση του μοντέλου, ενώ ο χρόνος εκπαίδευσης αυξανόταν σημαντικά. Έτσι, ως optimal θεωρήθηκε η τιμή 1000.

Seed:

Για να καταφέρουμε να εξασφαλίσουμε επαναληψιμότητα στα δεδομένα μας και να αφαιρεθεί η τυχαιότητα, επιλέξαμε έναν σταθερό αριθμό seed 42.

Random forest parameters:

N_estimators (100-1000):

Επιλέχθηκε η τιμή 700, διότι παρατηρήθηκε ότι, παρόλο που η αύξηση της τιμής βελτιώνει την απόδοση του RF, ο χρόνος εκτέλεσης αυξανόταν σημαντικά λόγω της δημιουργίας πολλών δέντρων.

Max_depth (10-20):

Επιλέχθηκε η τιμή 15, καθώς η αύξηση της τιμής αυξάνει τον κίνδυνο overfitting, αν και προσφέρει σημαντική βελτίωση στην απόδοση του RF.

Min_samples_split (2-10):

Επιλέχθηκε η τιμή 4, που βρίσκεται στη μέση του εύρους τιμών, για να ισορροπήσει μεταξύ της πρόληψης του overfitting και της διατήρησης της απόδοσης του μοντέλου.

Min_samples_leaf (2-10):

Επιλέχθηκε η τιμή 2, διότι παρατηρήθηκε ότι η αύξηση της τιμής αυτής παραμέτρου βελτιώνει μόνο την απόδοση στο type_risk4, ενώ έπεφτε η συνολική απόδοση σε κάθε άλλο τύπο οχήματος.

Max_features ('sqrt', 'log2', ή float 0.1-1):

Συνήθως, σε αλγόριθμους RF προτιμάται η τιμή 'sqrt', και αυτή επιλέχθηκε και από εμάς για καλύτερη απόδοση.

Bootstrap (True, False):

Επιλέξαμε να έχουμε bootstrap, καθώς βελτιώνονται σημαντικά τα αποτελέσματα σε σύγκριση με την επιλογή της μη ύπαρξης bootstrap.

N_jobs (-1, 1, αριθμός πυρήνων):

Με την επιλογή της τιμής -1, χρησιμοποιούμε όλους τους διαθέσιμους πυρήνες.

Random_state:

Πρόκειται για τιμή τυχαιότητας όπως το seed στο XGBoost. Έχει επιλεγεί και εδώ η τιμή 42.

NeuralNetwork

Όσον αφορά την αρχιτεκτονική και την λειτουργία του νευρωνικού, το δίκτυο χρησιμοποιεί embeddings για τα κατηγορικά χαρακτηριστικά, μετατρέποντάς τα σε αριθμητική μορφή βάσει συγκεκριμένου μεγέθους ενσωμάτωσης. Τα αριθμητικά χαρακτηριστικά και οι ενσωματώσεις των κατηγορικών χαρακτηριστικών συνδυάζονται σε ένα ενιαίο σύνολο εισόδων. Το νευρωνικό δίκτυο αποτελείται από πολλά πλήρως συνδεδεμένα στρώματα με διαφορετικό αριθμό μονάδων, μειώνοντας σταδιακά τους νευρώνες, ενώ χρησιμοποιείται στρώμα dropout για την τυχαία απενεργοποίηση ορισμένων νευρώνων, προλαμβάνοντας το overfitting.

Parameter	Before Tuning	After Tuning
objective	reg:squarederror	reg:squarederror
eval_metric	rmse	rmse
learning_rate	0.05	0.01
max_depth	4	5
min_child_weight	1	5
subsample	0.7	0.8
colsample_bytree	0.7	0.8
n_estimators	500	1000
seed	42	42

Πίνακας 1: XGBoost Parameter Settings Before and After Tuning

	Before Tuning			After Tuning		
	Mean squared error	Average Absolute Error	R ² Score	Mean squared error	Average Absolute Error	R ² Score
Motorbikes	2298.58	30.097	0.564	2228.745	29.779	0.5779
Vans	8087.68	61.148	0.367	7846.43	60.345	0.386
Passenger Cars	10776.074	69.165	0.378	10693.593	69.07	0.383
Agricultural Vehicles	356.954	13.416	-0.266	311.899	12.15	-0.1068

Πίνακας 2: XGBoost Parameter Tuning Results

Parameter	Before Tuning	After Tuning
n_estimators	100	700
max_depth	10	15
min_samples_split	2	4
min_samples_leaf	2	2
max_features	log2	sqrt
bootstrap	False	True
n_jobs	-1	-1
random_state	42	42

Πίνακας 3: RandomForest Parameter Settings Before and After Tuning

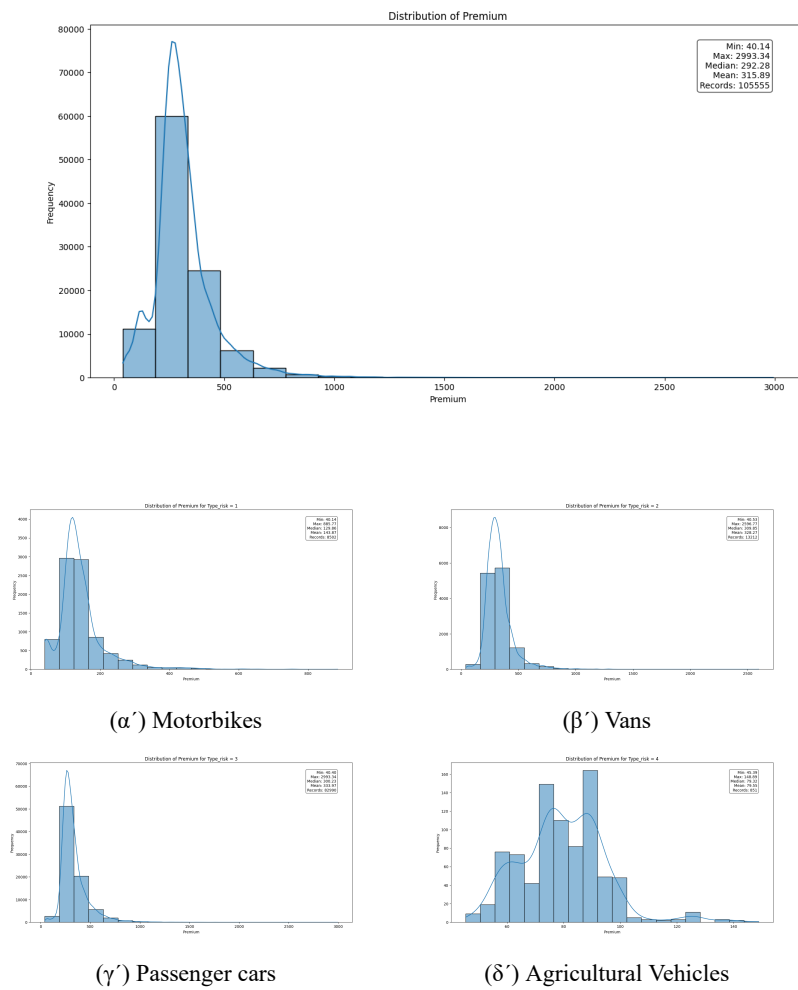
	Before Tuning			After Tuning		
	Mean squared error	Average Absolute Error	R ² Score	Mean squared error	Average Absolute Error	R ² Score
Motorbikes	2380.952	30.542	0.549	2265.092	29.42	0.571
Vans	8345.571	62.057	0.3476	8184.899	61.395	0.3601
Passenger Cars	11551.75	72.0927	0.333	10923.639	70.2268	0.3701
Agricultural Vehicles	282.682	11.586	-0.0032	267.008	11.477	0.0524

Πίνακας 4: Random Forest Parameter Tuning Results

Vehicle Type	Mean Squared Error	Average Absolute Error	R ² Score
Motorbikes	3594.674	36.799	0.3192
Vans	9117.373	64.3317	0.2872
Passenger Cars	11586.471	72.751	0.331
Agricultural Vehicles	1375.816	29.626	-3.8825

Πίνακας 5: Neural Network Performance Metrics

5 Διαγράμματα



Εικ. 1: Comparison of Different Vehicle Types

Παρατήρηση 1 Στο πρώτο διάγραμμα παρουσιάζεται η κατανομή των ασφαλίσεων για όλες τις καταχωρίσεις. Τα επόμενα διαγράμματα δείχνουν την κατανομή των ασφαλίσεων για κάθε κατηγορία οχημάτων ξεχωριστά.

Εύκολα διαπιστώνεται από το πρώτο ολικό διάγραμμα ότι οι ασφαλιστικές τιμές πάνω από 500 είναι ελάχιστες και δεν επηρεάζουν σημαντικά το τελικό αποτέλεσμα. Ωστόσο, όταν κατηγοριοποιήσαμε τα δεδομένα, παρατηρήσαμε ότι η διασπορά των τιμών στα αγροτικά οχήματα ήταν μεγαλύτερη, με αποτέλεσμα η διαφοροποίηση του μοντέλου ανά κατηγορία οχήματος να είναι απαραίτητη.

6 User Interface

Το user interface της εφαρμογής αναπτύχθηκε με χρήση της Python και ειδικότερα του framework Kivy, καθώς και της συλλογής από γραφικά στοιχεία KivyMD. Στην εφαρμογή μας υπάρχουν πέντε διαφορετικές "οθόνες":

1. Η οθόνη του login
2. Η οθόνη συμπλήρωσης στοιχείων του πελάτη που πρόκειται να ασφαλίσει το όχημά του.
3. Η οθόνη συμπλήρωσης στοιχείων του οχήματος που πρόκειται να ασφαλιστεί.
4. Η οθόνη συμπλήρωσης στοιχείων παλαιότερων συμβολαίων που είχε ο πελάτης στην εταιρεία.
5. Η οθόνη παρουσίασης της προτεινόμενης ετήσιας τιμής χρέωσης του πελάτη με βάση τα στοιχεία που συμπληρώθηκαν.

6.1 Login

Η οθόνη του login είναι η αρχική οθόνη της εφαρμογής [Εικ. 2] στην οποία ο χρήστης - υπάλληλος της εταιρείας θα πρέπει να συμπληρώσει τα σωστά στοιχεία σύνδεσής του (username και password) και στην συνέχεια να πατήσει το κουμπί "LOG IN". Σε περίπτωση που ένα από τα δύο πεδία μείνει κενό, ο χρήστης θα λάβει το αντίστοιχο μήνυμα λάθους [Εικ. 3α']. Σε περίπτωση που τα στοιχεία σύνδεσης δεν είναι σωστά, ο χρήστης θα λάβει διαφορετικό μήνυμα λάθους [Εικ. 3β'].


Έχει προβλεφθεί και δημιουργηθεί μόνο ένας λογαριασμός υπαλλήλου. Έτσι, για να πάμε στην επόμενη οθόνη θα πρέπει να συμπληρώσουμε στο πεδίο username: **admin_1** και στο πεδίο password: **12345**. Αφού συμπληρώσουμε αυτά τα στοιχεία σωστά και πατήσουμε το κουμπί "LOG IN" μεταφερόμαστε στην δεύτερη οθόνη [Εικ. 4].

6.2 Στοιχεία πελάτη

Στην οθόνη συμπλήρωσης στοιχείων του πελάτη [Εικ. 4], ο χρήστης-υπάλληλος της εταιρείας θα πρέπει να συμπληρώσει τα στοιχεία του ανθρώπου που ενδιαφέρεται να ασφαλίσει το όχημά του. Ειδικότερα, υπάρχουν δύο πεδία επιλογής ημερομηνίας ("Date of Birth", "License Issue Date"), τα οποία όταν επιλεγθούν εμφανίζεται ένα ημερολόγιο [Εικ. 5α'] προκειμένου να επιλεγθεί η κατάλληλη ημερομηνία. Πατώντας το πεδίο "Area" ο χρήστης βλέπει ένα μενού δύο επιλογών [Εικ. 5β'] από τις οποίες θα πρέπει



Εικ. 2: Οθόνη login



(α') Κενό πεδίο

(β') Λάθος στοιχεία

Εικ. 3: Μηνύματα λάθους στο login

να επιλέξει μία. Στο πεδίο "Seniority" ο χρήστης θα πρέπει να πληκτρολογήσει έναν αριθμό που προσδιορίζει τα χρόνια που ο συγκεκριμένος πελάτης είναι ασφαλισμένος στην εταιρεία.

Αφού συμπληρωθούν όλα τα πεδία ο χρήστης θα πρέπει να πατήσει το κουμπί "NEXT" για να μεταφερθεί στην επόμενη οθόνη [Εικ. 6]. Σε περίπτωση που επιθυμεί να πάει στην οθόνη του login [Εικ. 2] θα πρέπει να πατήσει το κουμπί "GO BACK".

Εικ. 4: Οθόνη συμπλήρωσης στοιχείων πελάτη

(α') Ημερολόγιο


(β') Μενού επιλογών

Εικ. 5: Παραδείγματα εισόδου

6.3 Στοιχεία οχήματος

Σε αυτήν την οθόνη [Εικ. 6], ο χρήστης-υπάλληλος της εταιρείας θα πρέπει να συμπληρώσει τα στοιχεία του οχήματος το οποίο επιθυμεί να ασφαλίσει ο πελάτης. Ειδικότερα, για τα πεδία "Type of vehicle", "Type of fuel", "Second driver" ο χρήστης θα πρέπει να πατήσει καθένα από αυτά τα πεδία και να επιλέξει μία από τις επιλογές που εμφανίζονται στο κάθε μενού επιλογών (ενδεικτικά [Εικ. 7α']). Στα υπόλοιπα πεδία ο χρήστης θα πρέπει να πληκτρολογήσει έναν αριθμό σύμφωνα με τις υποδείξεις του κάθε πεδίου (ενδεικτικά [Εικ. 7β']).

Για να μεταβεί στην επόμενη οθόνη [Εικ. 8] θα πρέπει να πατήσει το κουμπί "NEXT" ενώ για να πάει στην προηγούμενη οθόνη [Εικ. 4] συμπλήρωσης των στοιχείων του πελάτη θα πρέπει να πατήσει το κουμπί "GO BACK".



The screenshot shows a web application window titled "SafeWheels". The main heading is "Please fill in the vehicle's information:". Below this, there are nine input fields arranged in a 3x3 grid. The first row contains "Type of vehicle" (with a car icon), "Type of fuel" (with a fuel pump icon), and "Registration Year" (with a calendar icon and a "YYYY" placeholder). The second row contains "Second driver" (with a person icon), "Horse Power", and "Cylinder Capacity". The third row contains "Weight" (with a scale icon), "Length", and "Value" (with a price tag icon). At the bottom of the form are two buttons: "GO BACK" and "NEXT".

Εικ. 6: Οθόνη συμπλήρωσης στοιχείων οχήματος προς ασφάλιση

(α') Παράδειγμα μενού επιλογών

(β') Παράδειγμα συμπλήρωσης πεδίου

Εικ. 7: Παραδείγματα εισόδου

6.4 Στοιχεία συμβολαίου

Στην οθόνη συμπλήρωσης στοιχείων συμβολαίου [Εικ. 8] ο χρήστης-υπάλληλος της εταιρείας θα πρέπει να συμπληρώσει στοιχεία που αφορούν παλαιότερα συμβόλαια που είχε ο πελάτης στην εταιρεία. Υπάρχουν τρία πεδία επιλογής ημερομηνίας ("Start Contract", "Last renewal", "Next renewal"), τα οποία όταν επιλεγθούν εμφανίζεται ημερολόγιο (ενδεικτικά [Εικ. 9α']). Τα πεδία "Distribution Channel" και "Payment" είναι πεδία που κατά την επιλογή τους εμφανίζεται μενού επιλογών (ενδεικτικά [Εικ. 9β']), ενώ τα υπόλοιπα πρέπει να συμπληρωθούν με πληκτρολόγηση σύμφωνα με τις υποδείξεις των πεδίων.

Για την μετάβαση στην προηγούμενη οθόνη [Εικ. 6] ο χρήστης θα πρέπει να πατήσει το κουμπί "GO BACK". Διαφορετικά, βρισκόμαστε στο σημείο που έχουν συμπληρωθεί όλα τα στοιχεία και ο χρήστης θα πρέπει να πατήσει το κουμπί "CALCULATE" προκειμένου να μεταβεί στην τελευταία οθόνη [Εικ. 10].

The screenshot shows the SafeWheels logo at the top. Below it, a light blue box contains the text "Please fill in the contract information:". Inside this box, there are nine input fields arranged in a 3x3 grid. The first row contains "Start Contract", "Last renewal", and "Next renewal", each with a calendar icon and a placeholder "MM/DD/YYYY". The second row contains "Distribution Channel", "Payment", and "Claims", each with a car icon. The third row contains "Policies", "Lapse", and "Ratio claims", each with a car icon. At the bottom of the box are two buttons: "GO BACK" and "CALCULATE".

Εικ. 8: Οθόνη συμπλήρωσης στοιχείων οχήματος προς ασφάλιση

The left screenshot shows the "Start Contract" field with a calendar pop-up. The calendar is for May 2024, and the date 10 is selected. The right screenshot shows the "Payment" field with a dropdown menu open, displaying "Half-yearly" and "Annual" options.

(α') Παράδειγμα ημερολογίου


(β') Παράδειγμα μενού επιλογών

Εικ. 9: Παραδείγματα εισόδου

6.5 Οθόνη προτεινόμενης χρέωσης

Σε αυτήν την οθόνη [Εικ. 10], ο χρήστης-υπάλληλος της εταιρείας βλέπει την προτεινόμενη τιμή ασφάλισης του οχήματος που πρόκειται να ασφαλίσει ο πελάτης. Πατώντας το κουμπί "GO BACK" μπορεί να μεταβεί στην προηγούμενη οθόνη [Εικ. 8], ενώ πατώντας το κουμπί "LOGOUT" μεταβαίνει στην αρχική οθόνη της εφαρμογής [Εικ. 2].

Αξίζει να σημειωθεί πως ο χρήστης μπορεί να πηγαίνει προς τα πίσω και να αλλάζει στοιχεία ανά πάσα στιγμή. Κάθε φορά που πατά το κουμπί "CALCULATE" της προτελευταίας οθόνης [Εικ. 8], όλα τα ανανεωμένα στοιχεία δίνονται στο μοντέλο προκειμένου να βγει η προτεινόμενη τιμή χρέωσης.



Εικ. 10: Οθόνη παρουσίασης προτεινόμενης τιμής χρέωσης

6.6 Γενικές παρατηρήσεις για το ui

//κενά πεδία

7 Οπτικοποίηση και αξιολόγηση αποτελεσμάτων


7.1 Παρουσίαση των αποτελεσμάτων

Για την αξιολόγηση των μοντέλων χρησιμοποιήσαμε το mean squared error, το absolute error και το ποσοστό των προβλέψεων που ήταν εντός ενός ποσοστού της πραγματικής τιμής. Τα αποτελέσματα για κάθε μοντέλο όταν έχει εκπαιδευθεί στο σύνολο των δεδομένων φαίνονται στον πίνακα 6 και στα διάγραμμα 11, 12, 13. Από αυτήν την αξιολόγηση φαίνεται ότι το πιο ακριβές μοντέλο είναι το XGBoost.

Επίσης παρατηρήσαμε ότι υπάρχουν στα δεδομένα μας 4 διαφορετικές κατηγορίες οχημάτων και για τα μοντέλα του Random Forest και XGBoost που έχουν εκπαιδευθεί στο σύνολο των δεδομένων κάναμε ξεχωριστή αξιολόγηση ανα κατηγορία (πίνακες 7, 8 και διαγράμματα 16, 17). Ακόμη κάναμε ανάλυση για την σημασία των μεταβλητών σε αυτά τα μοντέλα (Πίνακες 14, 15).

	Mean squared error	Absolute error	Percentage within 10%
XGBoost	10370.87	66.19	34.87
Random Forest	10852.02	67.38	33.36
Neural network	11689.55	70.16	20.00

Πίνακας 6: Αξιολόγηση των μοντέλων




Εικ. 11: Μοντέλο XGBoost που εκπαιδεύτηκε στο σύνολο των δεδομένων


Παρατηρήσαμε ότι το Type risk παίζει πολύ σημαντικό ρόλο για το XGBoost και σημαντικό ρόλο στο Random Forest καθώς και ότι υπήρχε πολύ χαμηλή ακρίβεια στις μικρότερες κατηγορίες οπότε αποφασίσαμε να δοκιμάσουμε να εκπαιδεύσουμε διαφορετικό μοντέλο για κάθε κατηγορία. Αυτό βελτίωσε αρκετά την ακρίβεια του XGBoost [πίνακας 9, διάγραμμα 16], λίγο την ακρίβεια του random forest [πίνακας 10, διάγραμμα 17] ενώ η ακρίβεια του νευρωνικού μειώθηκε [πίνακας 11, διάγραμμα 20].

Πραγματοποιήσαμε και μελέτη της σημαντικότητας των features στο XGBoost [διάγραμμα 21] και το Random Forest [διάγραμμα 22]

Απο την παραπάνω ανάλυση προκύπτει ότι το καλύτερο μας μοντέλο είναι το XGBoost όταν εκπαιδευθεί ξεχωριστά για κάθε κατηγορία οχήματος. Η ακρίβεια του είναι 34.68 % των προβλέψεων είναι εντός 10 % της πραγματικής τιμής. [διάγραμμα 23]



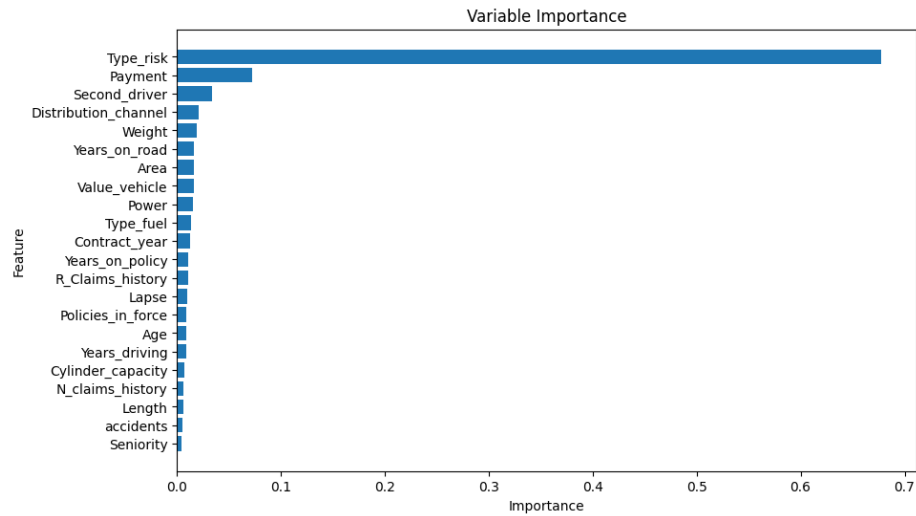
Εικ. 12: Μοντέλο Random Forest που εκπαιδεύτηκε στο σύνολο των δεδομένων




Εικ. 13: Μοντέλο Νευρωνικού δικτύου που εκπαιδεύτηκε στο σύνολο των δεδομένων

	Mean squared error	Absolute error	Percentage within 10%
Μοτοσυκλέτα	2358.08	30.92	35.25
Βανάκι	8266.77	61.80	37.50
Επιβατικό όχημα	11574.03	70.76	34.50
Αγροτικό όχημα	2348.79	27.96	26.92

Πίνακας 7: Αξιολόγηση XGBoost ανα κατηγορία




Εικ. 14: Μοντέλο XGBoost που εκπαιδεύτηκε σε όλα τα δεδομένα




Εικ. 15: Μοντέλο Random Forest που εκπαιδεύτηκε σε όλα τα δεδομένα

	Mean squared error	Absolute error	Percentage within 10%
Μοτοσυκλέτα	2229.48	29.05	36.54
Βανάκι	8586.59	62.96	36.57
Επιβατικό όχημα	12159.72	72.34	32.58
Αγροτικό όχημα	829.67	20.90	29.48


Πίνακας 8: Αξιολόγηση Random Forest ανα κατηγορία




Εικ. 16: Μοντέλο XGBoost που εκπαιδεύτηκε στο σύνολο των δεδομένων ξεχωριστή αξιολόγηση



Εικ. 17: Μοντέλο Random Forest που εκπαιδεύτηκε στο σύνολο των δεδομένων ξεχωριστή αξιολόγηση




Εικ. 18: Μοντέλο XGBoost που εκπαιδεύτηκε ξεχωριστά για κάθε κατηγορία



Εικ. 19: Μοντέλο Random Forest που εκπαιδεύτηκε ξεχωριστά για κάθε κατηγορία

	Mean squared error	Absolute error	Percentage within 10%
Μοτοσυκλέτα	2228.74	29.77	38.13
Βανάκι	7846.43	60.34	38.07
Επιβατικό όχημα	10693.59	69.07	33.66
Αγροτικό όχημα	311.89	12.15	51.38

Πίνακας 9: Αξιολόγηση XGBoost ανα κατηγορία



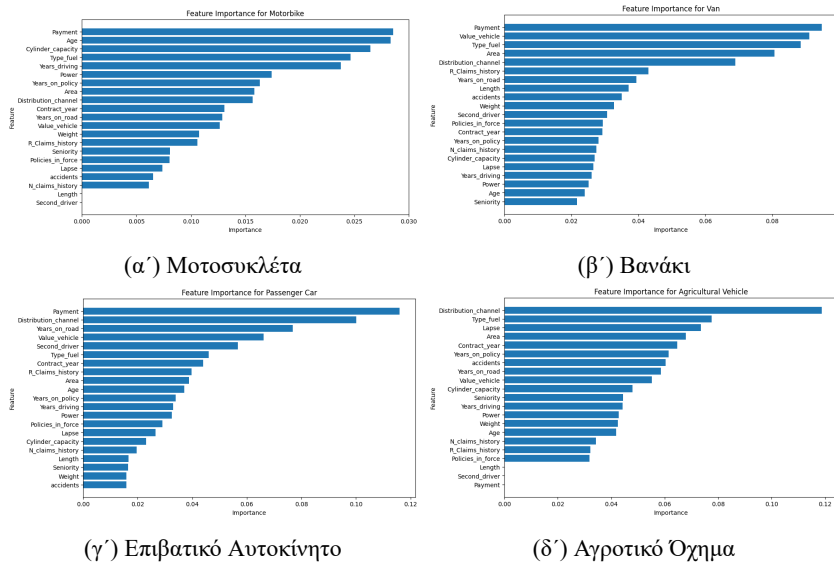
Εικ. 20: Μοντέλο Νευρωνικού δικτύου που εκπαιδεύτηκε ξεχωριστά για κάθε κατηγορία

	Mean squared error	Absolute error	Percentage within 10%
Μοτοσυκλέτα	2265.09	29.42	37.32
Βανάκι	8184.89	61.39	37.01
Επιβατικό όχημα	10923.63	70.22	32.51
Αγροτικό όχημα	267.00	11.47	55.55

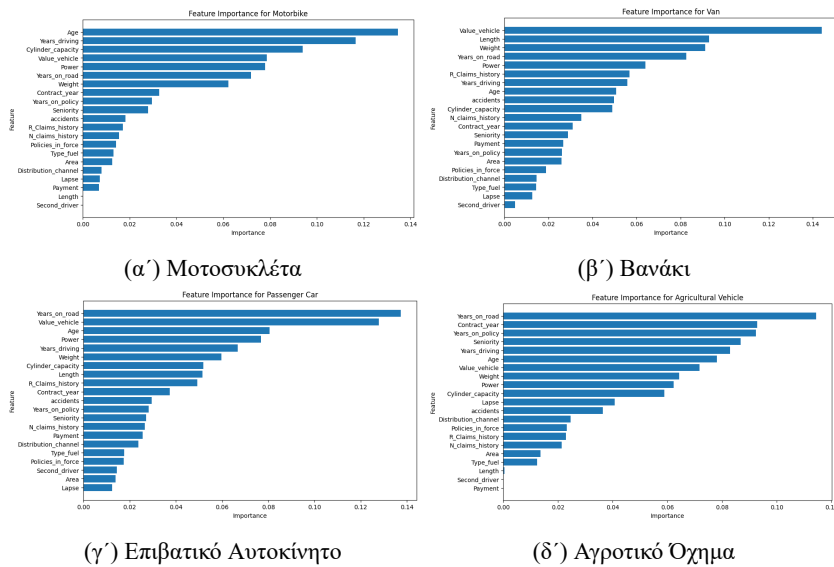
Πίνακας 10: Αξιολόγηση Random Forest ανα κατηγορία

	Mean squared error	Absolute error	Percentage within 10%
Μοτοσυκλέτα	3391.05	36.22	20.46
Βανάκι	8966.14	62.96	23.95
Επιβατικό όχημα	11465.31	71.66	22.41
Αγροτικό όχημα	1325.41	29.64	12.73


Πίνακας 11: Αξιολόγηση Νευρωνικού δικτύου ανα κατηγορία



Εικ. 21: Μοντέλο XGBoost που εκπαιδεύτηκε ξεχωριστά ανα κατηγορία



Εικ. 22: Μοντέλο Random Forest που εκπαιδεύτηκε ξεχωριστά ανα κατηγορία



Εικ. 23: Μοντέλο Νευρωνικού δικτύου που εκπαιδεύτηκε ξεχωριστά για κάθε κατηγορία συγκεντρωμένα αποτελέσματα

7.2 Σχολιασμός των αποτελεσμάτων

Παρατηρούμε ότι ακόμα και το καλύτερο μοντέλο μας δεν πετυχαίνει την απολύτη ακρίβεια αν και όπως φαίνεται στο διάγραμμα σχεδόν το 90 % των προβλέψεων είναι εντός του 40 % της πραγματικής τιμής ενώ λιγότερες απο 3 % των προβλέψεων έχουν ξεφύγει πάνω απο 80 % της πραγματικής τιμής. Αυτή η αποκλήση μπορεί να οφείλετε σε έλλειψη πληροφορίας απο το δεδομένα μας αφού ενδέχεται η ασφαλιστική εταιρεία να μην δημοσίευσε όλες της παραμέτρους που χρησιμοποιεί για να χρεώσει τους πελάτες της(π.χ αν έκανε επιπλέον εκπτώσεις για να κερδίσει μερίδιο στην αγορά)

Σχετικά με την σημαντικότητα των χαρακτηριστικών είναι λογικό που ο τρόπος πληρωμής είναι το πιο σημαντικό χαρακτηριστικό στις 3 απο τις 4 κατηγορίες αφού η εξόφληση του πόσου για όλο τον χρόνο παρέχει μεγαλύτερη σταθερότητα στα έσοδα της ασφαλιστικής οπότε η τιμή είναι καλύτερη. (διάγραμμα που δεν έχω βάλει ακόμα) Παρατηρούμε επίσης ότι μεγάλη σημασία έχει και ο τρόπος που αγοράστηκε η ασφάλεια αφού όσοι αγόρασαν την ασφάλεια κατευθείαν από την εταιρία έχουν καλύτερη τιμή απο όσους την αγόρασαν από τρίτους.(διάγραμμα που δεν έχω βάλει ακόμα) Σημαντική είναι και η συνολική αξία του οχήματος αφού όσο πιο ακριβό είναι τόσο πιο πολύ κοστίζει η επισκευή. Παρατηρούμε ότι αυτό είναι σημαντικότερος παράγωντας απόφασης στις κατηγορίες με μεγαλύτερο εύρος αξιών. Για της μοτοσυκλέτες είναι λογικό τα πιο σημαντικά χαρακτηριστικά να είναι ο κύβισμος και η ηλικία του οδηγού αφού οι νέοι οδηγοί και η μηχανές με υψηλό κυβισμό προκαλούν πιο πολλά ατυχήματα. Για τα επιβατικά αυτοκίνητα η ηλικία του αυτοκινήτου είναι σημαντική γιατί τα παλαιότερα αυτοκίνητα είναι πιο πιθανό να έχουν βλάβες. Αξιοσημείωτο είναι και ότι το ιστορικό ατυχημάτων και το πόσα χρόνια έχει κάποιος την ίδια ασφαλιστική δεν παίζει πολύ σημαντικό ρόλο στην τελική τιμή σε σχέση με άλλες παραμέτρους.

8 Οδηγίες εγκατάστασης

8.1 Εγκατάσταση της python και δημιουργία virtual environment

Για να μπορέσει να λειτουργήσει η εφαρμογή χρειάζεται αρχικά εγκατάσταση της Python 3.12.2 και μετά την δημιουργία ενός virtual environment ώστε να εγκατασταθούν εκεί η βιβλιοθήκες της python και να μην υπάρχουν συγκρούσεις που προκύπτουν απο διαφορά εκδόσεων. Για την δημιουργία του virtual environment δημιουργούμε ένα φάκελο μέσα στον οποίο θα εγκατασταθεί το περιβάλλον και ότι άλλο χρειαστούμε για την εφαρμογή (π.χ. ονομάζεται app) και ανοίγουμε ένα τερματικό στα Windows και πλοηγούμαστε εκεί. Με την εντολή

```
python3 -m venv virt
```

δημιουργούμε το περιβάλλον και με την εντολή

```
virt\Scripts\activate
```

το ενεργοποιούμε. Με αυτή την εντολή αναβαθμίζουμε και το pip

```
python.exe -m pip install --upgrade pip
```


8.2 Εγκατάσταση των βιβλιοθηκών απαραίτητων για την εφαρμογή

Η εφαρμογή μας για το γραφικό περιβάλλον χρησιμοποιεί kivy το οποίο εγκαθιστούμε με τις εντολές:

```
git clone https://github.com/kivymd/KivyMD.git --depth 1
cd KivyMD
pip install .
```

Για να εγκατασταθούν οι υπόλοιπες απαραίτητες βιβλιοθήκες οι εντολές είναι:

```
pip install numpy==1.26.4
pip install pandas==2.2.2
pip install joblib==1.4.2
pip install xgboost==2.0.3
```

Για να τρέξει η εφαρμογή πλοηγούμαστε στον φάκελο με τα αρχεία ui και xgboostModels χρησιμοποιούμε την εντολή:

```
python ui\front.py
```

και ακολουθούμε τις οδηγίες χρήσης στην επόμενη ενότητα.

8.3 Εγκατάσταση των βιβλιοθηκών απαραίτητων για τα python scripts και τα γραφήματα

Σε περίπτωση που θέλετε να τρέξετε εκτός απο την εφαρμογή και τα scripts με τα μοντέλα μας πρέπει να τρέξετε τις εντολές:

```
pip install torch==2.3.0 pip install scikit-learn==1.4.2 pip install matplotlib==3.8.4
```